

# Guia Teórico Completo de Probabilidade e Estatística

Vicente Duarte

Ano Letivo 2024/2025

---

## Resumo

Este guia teórico apresenta uma visão abrangente dos conceitos de Probabilidade e Estatística abordados nas séries de problemas do curso. O documento está estruturado de forma progressiva, abordando desde conceitos básicos de probabilidade até distribuições de variáveis aleatórias, probabilidade condicional e técnicas de inferência estatística. É especialmente útil como material de apoio ao estudo e à resolução dos exercícios propostos.

## Conteúdo

|          |  |          |
|----------|--|----------|
| <b>1</b> | <b>Conceitos Fundamentais de Probabilidade</b> | <b>4</b> |
| 1.1      | Espaço Amostral e Eventos . . . . .            | 4        |
| 1.2      | Definição de Probabilidade . . . . .           | 4        |
| 1.3      | Operações com Eventos . . . . .                | 4        |
| 1.4      | Probabilidade Condicional . . . . .            | 5        |
| 1.5      | Independência de Eventos . . . . .             | 5        |
| 1.6      | Teorema da Probabilidade Total . . . . .       | 6        |
| 1.7      | Teorema de Bayes . . . . .                     | 6        |

|          |  |           |
|----------|--|-----------|
| <b>2</b> | <b>Variáveis Aleatórias</b>                                  | <b>7</b>  |
| 2.1      | Definição e Tipos . . . . .                                  | 7         |
| 2.2      | Função de Probabilidade (V.A. Discretas) . . . . .           | 7         |
| 2.3      | Função Densidade de Probabilidade (V.A. Contínuas) . . . . . | 8         |
| 2.4      | Função de Distribuição Acumulada . . . . .                   | 8         |
| 2.5      | Valor Esperado (Média) . . . . .                             | 9         |
| 2.6      | Variância e Desvio Padrão . . . . .                          | 9         |
| <b>3</b> | <b>Distribuições Discretas Importantes</b>                   | <b>10</b> |
| 3.1      | Distribuição de Bernoulli . . . . .                          | 10        |
| 3.2      | Distribuição Binomial . . . . .                              | 10        |
| 3.3      | Distribuição Geométrica . . . . .                            | 11        |
| 3.4      | Distribuição de Poisson . . . . .                            | 12        |
| <b>4</b> | <b>Distribuições Contínuas Importantes</b>                   | <b>13</b> |
| 4.1      | Distribuição Uniforme Contínua . . . . .                     | 13        |
| 4.2      | Distribuição Exponencial . . . . .                           | 13        |
| 4.3      | Distribuição Normal . . . . .                                | 15        |
| <b>5</b> | <b>Variáveis Aleatórias Multidimensionais</b>                | <b>16</b> |
| 5.1      | Distribuição Conjunta . . . . .                              | 16        |
| 5.2      | Distribuições Marginais . . . . .                            | 17        |
| 5.3      | Distribuições Condicionais . . . . .                         | 17        |
| 5.4      | Independência de Variáveis Aleatórias . . . . .              | 17        |
| 5.5      | Covariância e Correlação . . . . .                           | 18        |
| 5.6      | Esperança Condicional . . . . .                              | 18        |
| <b>6</b> | <b>Teoremas Limite e Aproximações</b>                        | <b>19</b> |
| 6.1      | Lei dos Grandes Números . . . . .                            | 19        |
| 6.2      | Teorema Central do Limite . . . . .                          | 20        |
| 6.3      | Aproximação da Distribuição Binomial pela Normal . . . . .   | 21        |

|          |  |           |
|----------|--|-----------|
| <b>7</b> | <b>Estatística Inferencial Básica</b>      | <b>22</b> |
| 7.1      | Estimação Pontual . . . . .                | 22        |
| 7.2      | Intervalos de Confiança . . . . .          | 23        |
| 7.3      | Testes de Hipóteses . . . . .              | 24        |
| <b>8</b> | <b>Exemplo de Aplicação Completa</b>       | <b>25</b> |
| 8.1      | Contexto do Problema . . . . .             | 25        |
| 8.2      | Formulação do Teste de Hipóteses . . . . . | 25        |
| 8.3      | Cálculo da Estatística de Teste . . . . .  | 25        |
| 8.4      | Decisão . . . . .                          | 26        |
| 8.5      | Cálculo do Valor-p . . . . .               | 26        |
| 8.6      | Interpretação . . . . .                    | 26        |
| 8.7      | Intervalo de Confiança . . . . .           | 26        |
| 8.8      | Interpretação do Intervalo . . . . .       | 27        |
| 8.9      | Conclusão . . . . .                        | 27        |

# 1 Conceitos Fundamentais de Probabilidade

## 1.1 Espaço Amostral e Eventos

O espaço amostral, geralmente representado por  $\Omega$ , é o conjunto de todos os resultados possíveis de uma experiência aleatória. Um evento  $A$  é um subconjunto do espaço amostral, ou seja,  $A \subseteq \Omega$ .

### Exemplo

Ao lançar um dado de seis faces, o espaço amostral é  $\Omega = \{1, 2, 3, 4, 5, 6\}$ . O evento "sair um número par" corresponde ao conjunto  $A = \{2, 4, 6\}$ .

## 1.2 Definição de Probabilidade

A probabilidade de um evento  $A$ , denotada por  $P(A)$ , é uma medida da possibilidade de  $A$  ocorrer. Pela definição axiomática de Kolmogorov, a probabilidade deve satisfazer:

- (i)  $P(A) \geq 0$  para qualquer evento  $A$
- (ii)  $P(\Omega) = 1$
- (iii) Se  $A_1, A_2, \dots$  são eventos mutuamente exclusivos, então  $P(A_1 \cup A_2 \cup \dots) = P(A_1) + P(A_2) + \dots$

### Exemplo

No lançamento de uma moeda equilibrada,  $P(\text{cara}) = P(\text{coroa}) = \frac{1}{2}$ .  
Para o lançamento de um dado equilibrado,  $P(\text{sair } 3) = \frac{1}{6}$ .

## 1.3 Operações com Eventos

As operações básicas com eventos incluem:

- **União** ( $A \cup B$ ): evento que ocorre quando  $A$  ou  $B$  (ou ambos) ocorrem

- **Interseção** ( $A \cap B$ ): evento que ocorre quando  $A$  e  $B$  ocorrem simultaneamente
- **Complemento** ( $\bar{A}$  ou  $A^c$ ): evento que ocorre quando  $A$  não ocorre




Figura 1: Diagrama de Venn representando eventos  $A$  e  $B$ , sua interseção e o espaço amostral  $\Omega$

## 1.4 Probabilidade Condicional

A probabilidade condicional de um evento  $A$  dado que o evento  $B$  ocorreu, denotada por  $P(A|B)$ , é definida como:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}, \quad \text{onde } P(B) > 0 \quad (1)$$

### Fórmula Fundamental

A fórmula da probabilidade condicional pode ser reorganizada para obter:

$$P(A \cap B) = P(B) \times P(A|B) = P(A) \times P(B|A) \quad (2)$$

Esta é uma das fórmulas mais importantes e frequentemente utilizadas em problemas de probabilidade.

## 1.5 Independência de Eventos

Dois eventos  $A$  e  $B$  são independentes se e somente se:

$$P(A \cap B) = P(A) \times P(B) \quad (3)$$

Equivalentemente,  $A$  e  $B$  são independentes se  $P(A|B) = P(A)$  ou  $P(B|A) = P(B)$ .

### Exemplo

Ao lançar um dado duas vezes, o evento "tirar um número par no primeiro lançamento" é independente do evento "tirar um número menor que 3 no segundo lançamento".

## 1.6 Teorema da Probabilidade Total

Se  $B_1, B_2, \dots, B_n$  constituem uma partição do espaço amostral  $\Omega$  (ou seja, são mutuamente exclusivos e  $B_1 \cup B_2 \cup \dots \cup B_n = \Omega$ ), então para qualquer evento  $A$ :

$$P(A) = \sum_{i=1}^n P(A|B_i) \times P(B_i) \quad (4)$$




Figura 2: Ilustração do Teorema da Probabilidade Total: evento  $A$  distribuído entre a partição  $\{B_1, B_2, B_3\}$

## 1.7 Teorema de Bayes

O Teorema de Bayes permite inverter condições em probabilidades condicionais:

$$P(B_i|A) = \frac{P(A|B_i) \times P(B_i)}{\sum_{j=1}^n P(A|B_j) \times P(B_j)} \quad (5)$$

Numa forma mais simplificada, para dois eventos  $A$  e  $B$ :

$$P(B|A) = \frac{P(A|B) \times P(B)}{P(A)} \quad (6)$$

### Dica para Aplicar o Teorema de Bayes

O Teorema de Bayes é particularmente útil em problemas onde:

- São fornecidas probabilidades do tipo  $P(A|B)$
- Pede-se para calcular probabilidades do tipo  $P(B|A)$
- Existe informação adicional que surge após uma observação inicial

## 2 Variáveis Aleatórias

### 2.1 Definição e Tipos

Uma variável aleatória é uma função que associa um valor numérico a cada resultado do espaço amostral. As variáveis aleatórias podem ser:

- **Discretas:** assumem valores em conjunto finito ou enumerável (e.g., número de caras em 10 lançamentos de moeda)
- **Contínuas:** podem assumir qualquer valor em um intervalo contínuo (e.g., tempo de espera, altura de uma pessoa)

### 2.2 Função de Probabilidade (V.A. Discretas)

Para uma variável aleatória discreta  $X$ , a função de probabilidade  $p_X(x)$  (também chamada de função massa de probabilidade) é definida como:

$$p_X(x) = P(X = x) \quad (7)$$

Propriedades:

- (i)  $p_X(x) \geq 0$  para todo  $x$
- (ii)  $\sum_x p_X(x) = 1$

## 2.3 Função Densidade de Probabilidade (V.A. Contínuas)

Para uma variável aleatória contínua  $X$ , a função densidade de probabilidade  $f_X(x)$  satisfaz:

$$P(a \leq X \leq b) = \int_a^b f_X(x) dx \quad (8)$$

Propriedades:

- (i)  $f_X(x) \geq 0$  para todo  $x$
- (ii)  $\int_{-\infty}^{\infty} f_X(x) dx = 1$

## 2.4 Função de Distribuição Acumulada

A função de distribuição acumulada (FDA)  $F_X(x)$  de uma variável aleatória  $X$  é definida como:

$$F_X(x) = P(X \leq x) \quad (9)$$

Para variáveis aleatórias discretas:

$$F_X(x) = \sum_{t \leq x} p_X(t) \quad (10)$$

Para variáveis aleatórias contínuas:

$$F_X(x) = \int_{-\infty}^x f_X(t) dt \quad (11)$$




Figura 3: Comparação entre funções de distribuição acumulada para variáveis aleatórias contínuas e discretas



## 2.5 Valor Esperado (Média)

O valor esperado de uma variável aleatória  $X$ , denotado por  $E[X]$  ou  $\mu_X$ , representa o valor médio que esperamos obter se repetirmos a experiência muitas vezes.

Para variáveis aleatórias discretas:

$$E[X] = \sum_x x \cdot p_X(x) \quad (12)$$

Para variáveis aleatórias contínuas:

$$E[X] = \int_{-\infty}^{\infty} x \cdot f_X(x) dx \quad (13)$$

## 2.6 Variância e Desvio Padrão

A variância de uma variável aleatória  $X$ , denotada por  $\text{Var}(X)$  ou  $\sigma_X^2$ , mede a dispersão dos valores em torno da média:

$$\text{Var}(X) = E[(X - \mu_X)^2] = E[X^2] - (E[X])^2 \quad (14)$$

O desvio padrão  $\sigma_X$  é definido como a raiz quadrada da variância:

$$\sigma_X = \sqrt{\text{Var}(X)} \quad (15)$$

### Propriedades do Valor Esperado e Variância

Para constantes  $a$  e  $b$  e variáveis aleatórias  $X$  e  $Y$ :

$$E[aX + b] = aE[X] + b \quad (16)$$

$$\text{Var}(aX + b) = a^2 \text{Var}(X) \quad (17)$$

$$(18)$$

Se  $X$  e  $Y$  são independentes:

$$E[X \cdot Y] = E[X] \cdot E[Y] \quad (19)$$

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) \quad (20)$$

### 3 Distribuições Discretas Importantes

#### 3.1 Distribuição de Bernoulli

A distribuição de Bernoulli modela experiências com apenas dois resultados possíveis (sucesso ou fracasso). Se  $X$  é uma variável aleatória de Bernoulli com parâmetro  $p$  (probabilidade de sucesso), então:

$$P(X = x) = \begin{cases} p, & \text{se } x = 1 \\ 1 - p, & \text{se } x = 0 \end{cases} \quad (21)$$

Média:  $E[X] = p$

Variância:  $\text{Var}(X) = p(1 - p)$




Figura 4: Função de massa de probabilidade da distribuição de Bernoulli para diferentes valores de  $p$

#### 3.2 Distribuição Binomial

A distribuição binomial modela o número de sucessos em  $n$  tentativas independentes de Bernoulli, cada uma com probabilidade de sucesso  $p$ . Se  $X$  é uma variável aleatória binomial com parâmetros  $n$  e  $p$ , denotamos  $X \sim \text{Bin}(n, p)$  e:

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad k = 0, 1, 2, \dots, n \quad (22)$$

onde  $\binom{n}{k} = \frac{n!}{k!(n-k)!}$

Média:  $E[X] = np$

Variância:  $\text{Var}(X) = np(1 - p)$




Figura 5: Função de massa de probabilidade da distribuição binomial para diferentes valores de  $p$  com  $n = 10$

### 3.3 Distribuição Geométrica

A distribuição geométrica modela o número de tentativas necessárias até o primeiro sucesso em tentativas independentes de Bernoulli. Se  $X$  é uma variável aleatória geométrica com parâmetro  $p$  (probabilidade de sucesso em cada tentativa), então:

$$P(X = k) = (1 - p)^{k-1}p, \quad k = 1, 2, 3, \dots \quad (23)$$

Média:  $E[X] = \frac{1}{p}$

Variância:  $\text{Var}(X) = \frac{1-p}{p^2}$

### Propriedade de "Falta de Memória"

A distribuição geométrica é a única distribuição discreta que possui a propriedade de "falta de memória":

$$P(X > n + m | X > n) = P(X > m) \quad (24)$$

Esta propriedade significa que, se já esperamos  $n$  tentativas sem sucesso, a probabilidade de precisarmos de mais  $m$  tentativas é igual à probabilidade original de precisarmos de  $m$  tentativas.

## 3.4 Distribuição de Poisson

A distribuição de Poisson modela o número de ocorrências de um evento em um intervalo fixo, quando esses eventos ocorrem a uma taxa média constante e independentemente uns dos outros. Se  $X$  é uma variável aleatória de Poisson com parâmetro  $\lambda$  (taxa média de ocorrências), denotamos  $X \sim \text{Poisson}(\lambda)$  e:

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k = 0, 1, 2, \dots \quad (25)$$

Média:  $E[X] = \lambda$

Variância:  $\text{Var}(X) = \lambda$




Figura 6: Função de massa de probabilidade da distribuição de Poisson para diferentes valores de  $\lambda$

## 4 Distribuições Contínuas Importantes

### 4.1 Distribuição Uniforme Contínua

A distribuição uniforme contínua modela situações onde todos os valores em um intervalo  $[a, b]$  têm a mesma probabilidade de ocorrer. Se  $X$  é uma variável aleatória uniforme no intervalo  $[a, b]$ , denotamos  $X \sim \text{Uniforme}(a, b)$  e sua função densidade de probabilidade é:

$$f_X(x) = \begin{cases} \frac{1}{b-a}, & \text{se } a \leq x \leq b \\ 0, & \text{caso contrário} \end{cases} \quad (26)$$

Função de distribuição acumulada:

$$F_X(x) = \begin{cases} 0, & \text{se } x < a \\ \frac{x-a}{b-a}, & \text{se } a \leq x \leq b \\ 1, & \text{se } x > b \end{cases} \quad (27)$$

Média:  $E[X] = \frac{a+b}{2}$

Variância:  $\text{Var}(X) = \frac{(b-a)^2}{12}$



Figura 7: Funções de densidade e de distribuição da distribuição uniforme contínua no intervalo  $[0, 5]$

### 4.2 Distribuição Exponencial

A distribuição exponencial é frequentemente usada para modelar o tempo até a ocorrência de um evento, quando a taxa de ocorrência é constante. Se  $X$  é uma variável aleatória exponencial com parâmetro  $\lambda > 0$  (taxa), denotamos  $X \sim \text{Exp}(\lambda)$  e sua função densidade de probabilidade é:

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x}, & \text{se } x \geq 0 \\ 0, & \text{se } x < 0 \end{cases} \quad (28)$$

Função de distribuição acumulada:

$$F_X(x) = \begin{cases} 1 - e^{-\lambda x}, & \text{se } x \geq 0 \\ 0, & \text{se } x < 0 \end{cases} \quad (29)$$

Média:  $E[X] = \frac{1}{\lambda}$

Variância:  $\text{Var}(X) = \frac{1}{\lambda^2}$

#### Propriedade de "Falta de Memória"

Assim como a distribuição geométrica, a distribuição exponencial possui a propriedade de "falta de memória":

$$P(X > s + t | X > t) = P(X > s) \quad (30)$$

Isso significa que, se um componente já funcionou por  $t$  unidades de tempo sem falhar, a probabilidade de ele funcionar por mais  $s$  unidades de tempo é igual à probabilidade original de funcionar por  $s$  unidades de tempo.




Figura 8: Função densidade de probabilidade da distribuição exponencial para diferentes valores de  $\lambda$

### 4.3 Distribuição Normal

A distribuição normal (ou gaussiana) é uma das distribuições mais importantes em estatística. Se  $X$  é uma variável aleatória normal com média  $\mu$  e variância  $\sigma^2$ , denotamos  $X \sim N(\mu, \sigma^2)$  e sua função densidade de probabilidade é:

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad -\infty < x < \infty \quad (31)$$

A distribuição normal padrão, denotada por  $Z \sim N(0, 1)$ , tem média zero e variância unitária. Qualquer variável aleatória normal pode ser padronizada através da transformação  $Z = \frac{X-\mu}{\sigma}$ .

Média:  $E[X] = \mu$

Variância:  $\text{Var}(X) = \sigma^2$




Figura 9: Função densidade de probabilidade da distribuição normal para diferentes valores de  $\mu$  e  $\sigma$

### Propriedades da Distribuição Normal

- É simétrica em torno da média  $\mu$
- A moda e a mediana coincidem com a média
- Tem forma de sino, com ponto de inflexão em  $\mu \pm \sigma$
- Aproximadamente 68,27% dos valores estão a uma distância de até  $\sigma$  da média
- Aproximadamente 95,45% dos valores estão a uma distância de até  $2\sigma$  da média
- Aproximadamente 99,73% dos valores estão a uma distância de até  $3\sigma$  da média (regra 3-sigma)




Figura 10: Distribuição normal padrão com áreas correspondentes a diferentes intervalos de desvios padrão

## 5 Variáveis Aleatórias Multidimensionais

### 5.1 Distribuição Conjunta

Para variáveis aleatórias discretas  $X$  e  $Y$ , a função de probabilidade conjunta é:

$$p_{X,Y}(x,y) = P(X = x, Y = y) \quad (32)$$



Para variáveis aleatórias contínuas  $X$  e  $Y$ , a função densidade de probabilidade conjunta satisfaz:

$$P((X, Y) \in A) = \iint_A f_{X,Y}(x, y) dx dy \quad (33)$$

## 5.2 Distribuições Marginais

Para variáveis aleatórias discretas:

$$p_X(x) = \sum_y p_{X,Y}(x, y) \quad (34)$$

$$p_Y(y) = \sum_x p_{X,Y}(x, y) \quad (35)$$

Para variáveis aleatórias contínuas:

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy \quad (36)$$

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx \quad (37)$$

## 5.3 Distribuições Condicionais

Para variáveis aleatórias discretas:

$$p_{X|Y}(x|y) = \frac{p_{X,Y}(x, y)}{p_Y(y)}, \quad \text{se } p_Y(y) > 0 \quad (38)$$

$$p_{Y|X}(y|x) = \frac{p_{X,Y}(x, y)}{p_X(x)}, \quad \text{se } p_X(x) > 0 \quad (39)$$

Para variáveis aleatórias contínuas:

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}, \quad \text{se } f_Y(y) > 0 \quad (40)$$

$$f_{Y|X}(y|x) = \frac{f_{X,Y}(x, y)}{f_X(x)}, \quad \text{se } f_X(x) > 0 \quad (41)$$

## 5.4 Independência de Variáveis Aleatórias

Duas variáveis aleatórias  $X$  e  $Y$  são independentes se e somente se:

Para variáveis aleatórias discretas:

$$p_{X,Y}(x, y) = p_X(x) \cdot p_Y(y), \quad \text{para todo } x, y \quad (42)$$

Para variáveis aleatórias contínuas:

$$f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y), \quad \text{para todo } x, y \quad (43)$$

## 5.5 Covariância e Correlação

A covariância entre duas variáveis aleatórias  $X$  e  $Y$  é definida como:

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] = E[XY] - E[X]E[Y] \quad (44)$$

onde  $\mu_X = E[X]$  e  $\mu_Y = E[Y]$ .

A correlação entre  $X$  e  $Y$  é:

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} \quad (45)$$

onde  $\sigma_X = \sqrt{\text{Var}(X)}$  e  $\sigma_Y = \sqrt{\text{Var}(Y)}$ .

### Propriedades da Correlação

- $-1 \leq \rho_{X,Y} \leq 1$
- $\rho_{X,Y} = 1$  ou  $\rho_{X,Y} = -1$  se e somente se existe uma relação linear perfeita entre  $X$  e  $Y$
- $\rho_{X,Y} = 0$  se  $X$  e  $Y$  são independentes (a recíproca não é necessariamente verdadeira)

## 5.6 Esperança Condicional

A esperança condicional de uma variável aleatória  $X$  dado  $Y = y$  é definida como:

Para variáveis aleatórias discretas:

$$E[X|Y = y] = \sum_x x \cdot p_{X|Y}(x|y) \quad (46)$$

Para variáveis aleatórias contínuas:

$$E[X|Y = y] = \int_{-\infty}^{\infty} x \cdot f_{X|Y}(x|y) dx \quad (47)$$

A esperança condicional  $E[X|Y]$  pode ser vista como uma função de  $Y$ .

#### Lei da Esperança Total

$$E[X] = E[E[X|Y]] \quad (48)$$

Ou seja, a esperança incondicional de  $X$  pode ser obtida tomando a média ponderada das esperanças condicionais.

## 6 Teoremas Limite e Aproximações

### 6.1 Lei dos Grandes Números

A Lei dos Grandes Números assegura que a média aritmética de um grande número de variáveis aleatórias independentes e identicamente distribuídas converge para a esperança comum dessas variáveis.

Seja  $X_1, X_2, \dots, X_n$  uma sequência de variáveis aleatórias independentes e identicamente distribuídas com  $E[X_i] = \mu$ . Defina  $\bar{X}_n = \frac{1}{n}(X_1 + X_2 + \dots + X_n)$ . Então:

$$\bar{X}_n \xrightarrow{P} \mu \quad \text{quando } n \rightarrow \infty \quad (49)$$

onde  $\xrightarrow{P}$  denota convergência em probabilidade.

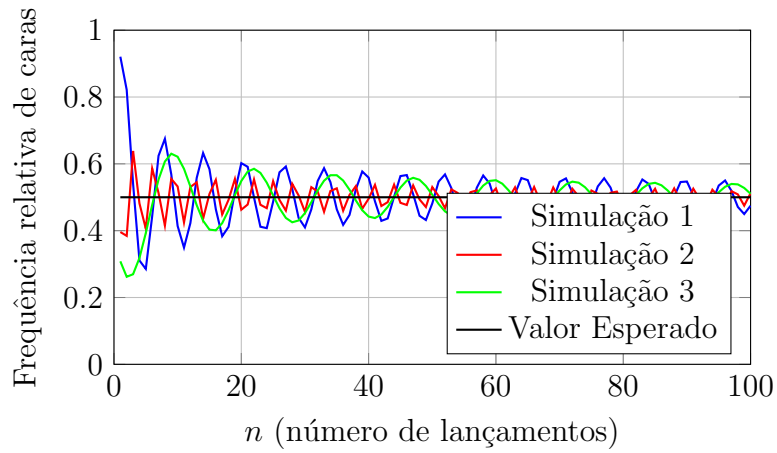


Figura 11: Ilustração da Lei dos Grandes Números: frequência relativa de caras em  $n$  lançamentos de uma moeda equilibrada

## 6.2 Teorema Central do Limite

O Teorema Central do Limite estabelece que a soma de um grande número de variáveis aleatórias independentes e identicamente distribuídas segue aproximadamente uma distribuição normal, independentemente da distribuição original das variáveis.

Seja  $X_1, X_2, \dots, X_n$  uma sequência de variáveis aleatórias independentes e identicamente distribuídas com  $E[X_i] = \mu$  e  $\text{Var}(X_i) = \sigma^2 < \infty$ . Defina  $S_n = X_1 + X_2 + \dots + X_n$ . Então, para  $n$  suficientemente grande:

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0, 1) \quad \text{quando } n \rightarrow \infty \quad (50)$$

onde  $\xrightarrow{d}$  denota convergência em distribuição.

### Aplicação do Teorema Central do Limite

O TCL permite aproximar a distribuição da soma de várias variáveis aleatórias por uma distribuição normal, facilitando enormemente os cálculos de probabilidades. Por exemplo, para  $n$  grande:

$$P\left(a \leq \frac{S_n - n\mu}{\sigma\sqrt{n}} \leq b\right) \approx \Phi(b) - \Phi(a) \quad (51)$$

onde  $\Phi$  é a função de distribuição acumulada da normal padrão.




Figura 12: Ilustração do Teorema Central do Limite: a soma de  $n$  variáveis aleatórias independentes e identicamente distribuídas aproxima-se de uma distribuição normal conforme  $n$  aumenta

### 6.3 Aproximação da Distribuição Binomial pela Normal

Para valores grandes de  $n$  e valores de  $p$  não muito próximos de 0 ou 1, a distribuição binomial  $\text{Bin}(n, p)$  pode ser aproximada por uma distribuição normal com média  $np$  e variância  $np(1 - p)$ :

$$\text{Bin}(n, p) \approx N(np, np(1 - p)) \quad (52)$$

Regra prática: a aproximação é considerada boa quando  $np > 5$  e  $n(1 - p) > 5$ .

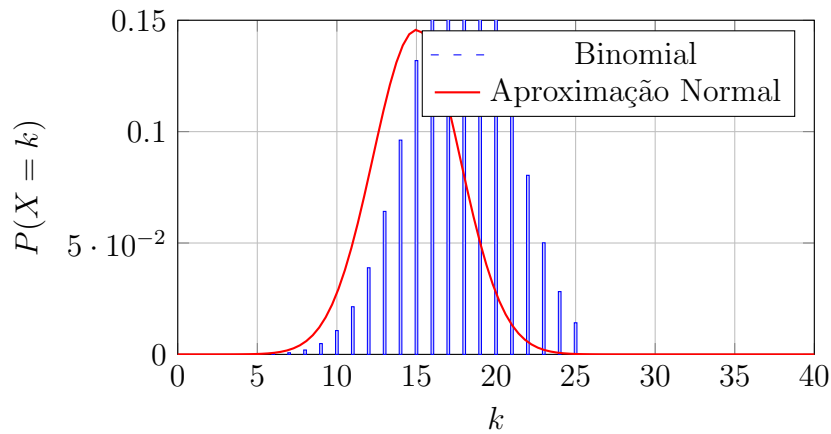


Figura 13: Aproximação da distribuição binomial pela distribuição normal

## 7 Estatística Inferencial Básica

### 7.1 Estimação Pontual

A estimação pontual consiste em utilizar uma única estatística (estimador) para estimar um parâmetro desconhecido da população.

- **Estimador:** função dos dados da amostra
- **Estimativa:** valor específico do estimador calculado a partir de dados amostrais

Propriedades desejáveis de um estimador:

- **Não-viesado:**  $E[\hat{\theta}] = \theta$  (o valor esperado do estimador é igual ao parâmetro)
- **Consistente:**  $\hat{\theta} \xrightarrow{P} \theta$  quando  $n \rightarrow \infty$  (o estimador converge em probabilidade para o parâmetro)
- **Eficiente:** tem a menor variância possível entre os estimadores não-viesados

Estimadores comuns:

$$\text{Média amostral: } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad (53)$$

$$\text{Variância amostral: } S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (54)$$

$$\text{Proporção amostral: } \hat{p} = \frac{X}{n} \quad (55)$$

## 7.2 Intervalos de Confiança

Um intervalo de confiança é um intervalo de valores que, com uma certa probabilidade (nível de confiança), contém o verdadeiro valor do parâmetro populacional.

Para a média populacional  $\mu$  de uma distribuição normal com variância  $\sigma^2$  conhecida, um intervalo de confiança de nível  $(1 - \alpha)$  é:

$$\bar{X} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \quad (56)$$

onde  $z_{\alpha/2}$  é o quantil de ordem  $1 - \alpha/2$  da distribuição normal padrão.

Se a variância  $\sigma^2$  é desconhecida e a amostra é de uma distribuição normal, utiliza-se a distribuição t de Student:

$$\bar{X} \pm t_{\alpha/2, n-1} \frac{S}{\sqrt{n}} \quad (57)$$

onde  $t_{\alpha/2, n-1}$  é o quantil de ordem  $1 - \alpha/2$  da distribuição t com  $n - 1$  graus de liberdade.

### Interpretação Correta de um Intervalo de Confiança

Um intervalo de confiança de 95% não significa que a probabilidade do parâmetro estar no intervalo é 95%. Significa que, se muitas amostras fossem coletadas e intervalos de confiança calculados, 95% desses intervalos conteriam o verdadeiro valor do parâmetro.

### 7.3 Testes de Hipóteses

Um teste de hipóteses é um procedimento para decidir se uma hipótese sobre a população é plausível, com base em dados amostrais.

- **Hipótese nula** ( $H_0$ ): hipótese que está sendo testada
- **Hipótese alternativa** ( $H_1$  ou  $H_a$ ): hipótese que será aceita se  $H_0$  for rejeitada
- **Estatística de teste**: função dos dados que é usada para decidir se  $H_0$  deve ser rejeitada
- **Região crítica**: conjunto de valores da estatística de teste que levam à rejeição de  $H_0$
- **Nível de significância** ( $\alpha$ ): probabilidade de rejeitar  $H_0$  quando ela é verdadeira (erro Tipo I)
- **Valor-p**: probabilidade de observar um valor da estatística de teste pelo menos tão extremo quanto o observado, supondo que  $H_0$  seja verdadeira

Para testar  $H_0 : \mu = \mu_0$  contra  $H_1 : \mu \neq \mu_0$  (teste bilateral) para uma distribuição normal com  $\sigma$  conhecido:

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \quad (58)$$

Rejeita-se  $H_0$  ao nível de significância  $\alpha$  se  $|Z| > z_{\alpha/2}$ .






Figura 14: Regiões de aceitação e crítica para um teste bilateral ao nível de significância  $\alpha = 5\%$

## 8 Exemplo de Aplicação Completa

### 8.1 Contexto do Problema

Suponha que uma empresa de semicondutores quer testar se um novo método de fabricação melhora a vida útil dos seus chips. A vida útil dos chips com o método atual segue aproximadamente uma distribuição normal com média  $\mu = 1200$  horas e desvio padrão  $\sigma = 150$  horas.

A empresa testa 36 chips produzidos com o novo método e obtém uma vida útil média de 1245 horas. Eles querem saber se há evidência estatística de que o novo método melhora a vida útil.

### 8.2 Formulação do Teste de Hipóteses

$$H_0 : \mu = 1200 \text{ (o novo método não melhora a vida útil)} \quad (59)$$

$$H_1 : \mu > 1200 \text{ (o novo método melhora a vida útil)} \quad (60)$$

### 8.3 Cálculo da Estatística de Teste

Considerando o desvio padrão conhecido:

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} = \frac{1245 - 1200}{150/\sqrt{36}} = \frac{45}{25} = 1.8 \quad (61)$$

## 8.4 Decisão

Para um teste unilateral com nível de significância  $\alpha = 0.05$ , o valor crítico é  $z_{0.05} = 1.645$ .

Como  $Z = 1.8 > 1.645$ , rejeitamos  $H_0$  ao nível de significância de 5%.

## 8.5 Cálculo do Valor-p

$$\text{Valor-p} = P(Z > 1.8) = 1 - \Phi(1.8) \approx 0.0359 \quad (62)$$

onde  $\Phi$  é a função de distribuição acumulada da normal padrão.

## 8.6 Interpretação

O valor-p de 0.0359 é menor que o nível de significância de 0.05, o que confirma nossa decisão de rejeitar  $H_0$ . Há evidência estatística para concluir que o novo método de fabricação melhora a vida útil dos chips.

## 8.7 Intervalo de Confiança

Um intervalo de confiança de 95% para a média da vida útil com o novo método é:

$$\bar{X} \pm z_{0.025} \frac{\sigma}{\sqrt{n}} = 1245 \pm 1.96 \cdot \frac{150}{\sqrt{36}} \quad (63)$$

$$= 1245 \pm 1.96 \cdot 25 \quad (64)$$

$$= 1245 \pm 49 \quad (65)$$

$$= [1196, 1294] \quad (66)$$

## 8.8 Interpretação do Intervalo

O intervalo de confiança de 95% para a média da vida útil dos chips produzidos com o novo método vai de 1196 a 1294 horas. Como este intervalo contém o valor 1200 (embora por uma margem pequena), isso sugere que a melhoria pode não ser tão substancial quanto se esperava inicialmente.

## 8.9 Conclusão

Embora haja evidência estatística para concluir que o novo método melhora a vida útil dos chips (teste de hipóteses), o intervalo de confiança sugere que a melhoria pode ser modesta. A empresa deve considerar outros fatores, como o custo da implementação do novo método, antes de tomar uma decisão final.

### Dica de Interpretação

Sempre considere tanto o resultado do teste de hipóteses quanto o intervalo de confiança ao tomar decisões baseadas em dados estatísticos. O teste de hipóteses fornece uma decisão binária (rejeitar ou não rejeitar), enquanto o intervalo de confiança fornece uma gama de valores plausíveis para o parâmetro, o que pode ser mais informativo para a tomada de decisões práticas.